

Documentación: Implementación de K-Means desde Cero

Introducción

Este proyecto implementa el algoritmo de K-Means desde cero sin usar `sklearn.cluster.KMeans`. Se utiliza `make_blobs` para generar un dataset de prueba.

El algoritmo agrupa los datos en clusters y usa el método del codo para encontrar el mejor número de clusters (k).

Requisitos

Para ejecutar el código, instala las librerías necesarias con:

```
pip install numpy matplotlib
```

Cómo Funciona el Algoritmo

Generación del dataset:

Se crean puntos de datos con `make_blobs()`.

Cálculo de distancias:

Se usa la distancia euclídea para asignar cada punto al cluster más cercano.

Inicialización de centroides:

Se puede elegir entre:

Aleatoria: Se generan valores dentro del rango de los datos.

Desde puntos existentes: Se seleccionan puntos del dataset como centroides iniciales.

Asignación de clusters:

Cada punto se asigna al centroide más cercano.

Si hay empate, se asigna al cluster con menos puntos.

Actualización de centroides:

Se recalculan los centroides como el promedio de los puntos asignados a cada cluster.

Criterio de parada:

Se repiten los pasos hasta que los centroides no cambian o se alcanza un número máximo de iteraciones (`max_iter`).

Método del codo:

Se prueba con diferentes valores de k y se mide la Suma de Errores Cuadráticos (SSE) para determinar el mejor número de clusters.

Visualización

Se grafican los clusters con diferentes colores.

Los centroides finales se marcan con una X roja.

Conclusión

Este código implementa K-Means desde cero con:

Distancia euclídea.

Diferentes métodos de inicialización.

Equilibrio de tamaño en caso de empate.

Método del codo para seleccionar k.

Visualización de los clusters.

Es una solución simple y funcional para aplicar K-Means sin librerías avanzadas.